

CONFIDENTIEL - Ne pas redistribuer

Cette analyse vous est proposée à titre informatif.

Elle est susceptible de contenir des erreurs, omissions ou imprécisions.

Jean-François LARHER - Coach Profiler - +41 78 771 81 42 - jef@larher.ch

AUDIT DE CANDIDATURE IT - SUISSE ROMANDE

Candidat : Danny Waser | **Document analysé :** CV_FR.pdf (2 pages)

Limite : aucune offre d'emploi ni lettre de motivation n'a été fournie. Le matching est donc évalué sur le positionnement intrinsèque du CV, pas sur une annonce précise.

1. SCORECARD, POSITIONNEMENT ET VERDICT GLOBAL

Indicateur	Score	Lecture
Score global	78/100	Solide mais perfectible : différenciation technique forte, mais positionnement trop large et quelques affirmations insuffisamment étayées.
Score page 1	66/100	Le pitch et les expériences sont visibles, mais pas le bloc compétences ni une sélection nette de 2 à 4 preuves fortes.
Score ATS	83/100	Structure simple et textuelle, sections standards et parsing lisible. Pénalités : dates FR/EN hétérogènes et intitulés parfois ambigus.
Score recruteur	81/100	Très bonnes preuves open source et réalisations techniques. Risque : statut emploi/mandat/open source parfois difficile à distinguer.
Score IA	84/100	Très bonne densité sémantique sur LLM, CUDA, speech, RAG et inference. Bruit lié au multi-positionnement et à quelques compétences plus fortes que les preuves visibles.

Positionnement principal crédible : AI Systems / LLM Inference Engineer, avec spécialisation GPU et déploiement local.

Positionnements secondaires crédibles : Speech AI Engineer ; Generative AI / RAG Engineer.

Positionnement à présenter avec prudence : GPU Kernel / CUDA Engineer pur. Le CV montre une proximité réelle avec AutoAWQ, CUDA et l'inférence, mais les preuves visibles portent davantage sur build/compatibilité et intégration que sur la conception ou l'optimisation algorithmique de kernels eux-mêmes.

Verdict global : passe avec réserves. Le CV peut susciter un entretien sur des rôles AI Systems / inference / speech / GenAI, mais il gagnerait nettement à être recentré avant envoi ciblé.

Verdict pré-envoi : envoi déconseillé sans au minimum corriger les incohérences de preuve, harmoniser les dates et reconstruire la première page.

SCORES COACHING

- Risque de perception IA / généricité : 24/100 - risque faible. Le texte est spécifique et techniquement ancré ; le principal risque n'est pas la généricité mais la sur-promesse sur quelques formulations.

- Densité de preuves : 86/100 - très bonne. PR identifiées, dépôts, technologies, latence, durée de prototypage, volume de RAM/GPU et amélioration du WER donnent de la matière vérifiable.
- Cohérence CV / lettre / offre : non notée - aucune lettre ni offre fournie.

2. ANALYSE DU POSITIONNEMENT CIBLE

- Le titre « AI ENGINEER | GPU KERNELS & INFERENCE OPTIMIZATION » est différenciant et attire un hiring manager technique.
- L'expérience la plus récente est toutefois intitulée « Data Scientist » et couvre analyse opérationnelle, RAG, trading algorithmique et blockchain. Cela crée un décalage avec le titre très spécialisé GPU/inference.
- Le parcours soutient mieux un profil d'AI Systems Engineer transversal : LLM inference, speech, orchestration d'agents, déploiement sur hardware local, RAG et contributions open source.
- La spécialisation Speech AI est crédible : Coqui/STT, Common Voice FR, Whisper, VAD, OpenVoice, migration DeepSpeech vers STT.
- La cible « CUDA/GPU Kernel Engineer » reste possible, mais il faut démontrer précisément les kernels écrits, modifiés ou profilés, les outils de profiling utilisés, les gains obtenus et la part de code réellement produite.
- Les cibles trop larges (« Data Scientist », « Blockchain Developer », « Quant Developer », « Full-stack AI Engineer » toutes à la fois) doivent être évitées dans un même CV.

3. ANALYSE DU PITCH

Diagnostic : pitch trop long et trop affirmatif pour une lecture de 10 à 20 secondes. Il est techniquement riche mais présente presque toute la stack dans un seul paragraphe.

- Point fort : il donne immédiatement une couleur technique rare : CUDA, LLM inference, speech, open source.
- Point faible : « kernels CUDA/Triton sur-mesure » n'est pas démontré dans les expériences visibles.
- Point faible : « internals PyTorch » est ambigu ; le CV ne montre pas de contribution directe au dépôt PyTorch.
- Point faible : « aussi à l'aise pour optimiser un kernel CUDA que pour concevoir un serveur d'inférence distribué » est une auto-évaluation forte sans preuve comparative.
- Point de forme : « Ingénieur autodidacte » est honnête, mais placé en premier mot il attire l'attention sur l'absence de diplôme IT avant la valeur technique.

PITCH RECOMMANDÉ - VERSION PRUDENTE ET DÉFENDABLE

AI Systems Engineer spécialisé en inférence LLM, speech AI et déploiement GPU, avec des contributions mergées dans AutoAWQ, Hugging Face Transformers et Coqui-STT. Expérience de systèmes RAG, agents LLM, pipelines vocaux temps réel et inference locale sur GPU NVIDIA. Profil orienté R&D appliquée, optimisation et mise en production de systèmes IA.

4. LECTURE PREMIÈRE PAGE : PRÉSÉLECTION

Ce qui fonctionne : nom, titre, localisation, contacts et liens techniques sont visibles immédiatement ; le design est sobre et lisible.

- Les expériences Synthflow AI, Coqui/STT et Waser Technologies contiennent des preuves différenciantes dès la première page.
- La photo est professionnelle et ne gêne pas la lecture. Elle reste optionnelle.
- La page 1 est presque entièrement occupée par le pitch et quatre expériences détaillées. Le bloc « Compétences techniques », central pour ce profil, commence seulement en page 2.
- Un recruteur RH ne voit donc pas en 10 à 20 secondes une synthèse structurée des compétences clés.
- Les quatre sous-domaines de l'expérience la plus récente donnent un effet « catalogue » avant même les preuves les plus fortes du profil.

- Le CV ne montre pas de disponibilité, préavis, taux d'activité ou permis. À ajouter seulement si pertinent.
- Le numéro « +41 (0) 78... » est moins propre internationalement que « +41 78... ».
- Les dates mélangent Sep, Mar, Jan., March, Nov., Dec., July, Aug. : uniformiser au format mm.yyyy ou en français.

5. LECTURE RECRUTEUR / MANAGER / IA

- Le manager technique trouvera des éléments vérifiables : numéros de PR, dépôts, technologies, migrations, WER, latence sous la seconde, prototype en moins de deux semaines et hardware local.
- Les contributions open source constituent le meilleur différenciateur du dossier et doivent remonter plus haut.
- La section Waser Technologies est particulièrement riche, mais elle mélange produit, infrastructure, R&D et contribution open source. Séparer 2 à 3 réalisations majeures améliorerait la lisibilité.
- Le titre « Data Scientist » ne reflète pas complètement les missions RAG / LLM / smart contracts / quant. Un sous-titre descriptif peut aider sans changer le titre officiel, s'il correspond réellement au rôle.
- La séniorité technique paraît supérieure à ce que le diplôme formalise ; l'entretien cherchera probablement à vérifier profondeur CUDA, architecture, production et rôle exact dans chaque projet.

6. DIAGNOSTIC ATS ET PARSING

- Structure une colonne, texte sélectionnable et sections standard : bon niveau de parsing.
- Les liens GitHub/LinkedIn/HF/portfolio sont utiles ; conserver des libellés stables et des liens cliquables.
- Harmoniser les dates : 09.2024 - 03.2026, 01.2024 - 03.2024, etc.
- Harmoniser les langues de section : remplacer « Languages » par « Langages » et garder le CV en français, sauf noms de technologies.
- Éviter les caractères décoratifs non indispensables (étoiles GitHub, flèches) dans une version ATS stricte.
- Nom de fichier recommandé : Danny_Waser_CV_AI_Systems_Engineer.pdf ou Danny_Waser_CV_LLM_Inference_Engineer.pdf selon la cible.
- Le PDF est textuel et lisible ; aucun tableau complexe n'est visible dans la mise en page.

7. DIAGNOSTIC MATCHING IA ET MOTS-CLÉS

- Très bon noyau sémantique : CUDA, Triton, PyTorch, quantization, AWQ/GPTQ/GGUF, llama.cpp, vLLM, RAG, LoRA/SFT, Hugging Face, ASR, Whisper, Docker, CI/CD.
- Le problème n'est pas le manque de mots-clés mais leur dispersion. Le matching peut hésiter entre Data Scientist, GenAI Engineer, Speech Engineer, CUDA Engineer et AI Systems Engineer.
- Pour une offre donnée, conserver 3 à 5 catégories de compétences prioritaires et déplacer le reste en page 2.
- Sur une cible LLM Inference / AI Systems, faire remonter : Python, PyTorch, CUDA, vLLM/llama.cpp, quantization, Docker/Linux, inference GPU.
- Sur une cible Speech AI, faire remonter : ASR, Coqui/STT, Whisper, VAD, TFLite, FFmpeg, OpenVoice.
- Sur une cible GenAI/RAG, faire remonter : RAG, fine-tuning LoRA/SFT, Hugging Face, FastAPI, data pipelines, orchestration multi-agent.

8. DIAGNOSTIC MANIPULATION ATS / IA, PERCEPTION IA ET GÉNÉRICITÉ

Manipulation / prompt injection : aucun signal détecté dans le CV analysé.

Sur-optimisation ATS : signal faible à modéré. La section compétences est longue et certains outils semblent très spécifiques à des projets.

Perception IA / généricité : risque faible. Le texte contient beaucoup de détails spécifiques et peu de formules RH génériques.

Risque réel à corriger : sur-affirmation technique. Une formulation très spécialisée sans preuve détaillée peut être perçue comme du marketing technique.

- « kernels CUDA/Triton sur-mesure » -> à garder uniquement si vous pouvez citer le dépôt, le kernel, le changement et l'effet.
- « serveur d'inférence distribué » -> à garder si l'architecture distribuée est réellement implémentée ; sinon parler de serveur d'inférence ou d'architecture client-serveur.
- « latence minimale » -> préférer une mesure réelle si disponible, sinon « temps réel » suffit.

9. COACHING PRÉ-ENVOI : PREUVES MANQUANTES, QUESTIONS AU CANDIDAT, RÉÉCRITURES NATURELLES

- AutoAWQ : avez-vous écrit ou modifié des kernels CUDA/Triton eux-mêmes, ou principalement le build process et la compatibilité PyTorch ?
- PyTorch internals : quelle contribution ou quel travail précis justifie cette expression ?
- Waser Technologies : s'agit-il d'une société enregistrée, d'une raison individuelle, d'un projet entrepreneurial ou d'une activité indépendante ?
- Mozilla & Coqui-AI : étiez-vous salarié, mandataire, contractor ou contributeur open source bénévole ?
- Synthflow AI : contrat, mission freelance, stage ou emploi ? Quel périmètre de production réel a été déployé ?
- Idéal Isolation / DF Innovation : quelle proportion du rôle relevait de la data science, de GenAI/RAG, du trading et de la blockchain ?
- RAG : quels modèles, base vectorielle, framework ou métriques d'évaluation avez-vous réellement utilisés ?
- LLM inference : quels modèles, quantifications, débits, latences, tailles de contexte ou contraintes hardware pouvez-vous documenter ?
- CUDA/GPU : quels outils de profiling, si utilisés, et quels gains mesurés pouvez-vous défendre ?
- Situation actuelle depuis 03.2026 : activité, projet, recherche, disponibilité ou préavis ?

RÉÉCRITURES PRUDENTES

- « Optimisation de kernels CUDA : PR mergées... mise à jour du build process... » -> « Contributions AutoAWQ / AutoAWQ_kernels : amélioration du build et de la compatibilité PyTorch pour la compilation de kernels de quantification CUDA. »
- « aussi à l'aise pour optimiser un kernel CUDA que pour concevoir un serveur d'inférence distribué » -> « combine une compréhension low-level GPU avec la conception de systèmes d'inférence et de pipelines IA de bout en bout. »
- « latence minimale » -> « transcription vocale en temps réel avec Faster-Whisper et VAD dans une architecture client-serveur. »

10. ANALYSE LETTRE DE MOTIVATION SI FOURNIE

Aucune lettre de motivation n'a été fournie. Cette section ne peut donc pas être notée ni comparée au CV. Pour une candidature ciblée, la lettre devra reprendre 2 preuves du CV maximum et expliquer pourquoi le contexte du poste exige précisément ces compétences, sans répéter la liste technique.

11. RÉORGANISATION CONSEILLÉE DU CV

PAGE 1 - DÉCISION DE PRÉSÉLECTION

- Identité, coordonnées, Lausanne, liens techniques.

- Titre ciblé unique : « AI Systems Engineer | LLM Inference & GPU » ou variante selon l'offre.
- Pitch de 3 à 4 lignes maximum.
- Compétences clés en 4 blocs maximum : LLM Inference & GPU ; GenAI/RAG ; Speech AI ; Python/Linux/DevOps.
- 3 preuves fortes : contributions Coqui-STT ; contribution AutoAWQ/Hugging Face ; système inference/voice ou RAG pertinent pour l'offre.
- Expérience récente condensée : Idéal Isolation / DF Innovation avec 2 à 3 puces seulement, orientées vers la cible.
- Langues ; disponibilité/préavis/permis si pertinent.

PAGE 2 - PREUVES TECHNIQUES

- Synthflow AI détaillé.
- Coqui/STT / Common Voice détaillé.
- Waser Technologies détaillé avec 3 projets maximum.
- Compétences techniques étendues si elles ne tiennent pas en page 1.
- Contributions open source regroupées et hiérarchisées par pertinence.
- Formation et intérêts personnels en fin de CV.

12. RECOMMANDATIONS DE RÉÉCRITURE PRÊTES À COLLER

TITRE

AI SYSTEMS ENGINEER | LLM INFERENCE & GPU

PROFIL

AI Systems Engineer spécialisé en inférence LLM, speech AI et déploiement GPU, avec des contributions mergées dans AutoAWQ, Hugging Face Transformers et Coqui-STT. Expérience de systèmes RAG, agents LLM, pipelines vocaux temps réel et inference locale sur GPU NVIDIA. Profil orienté R&D appliquée, optimisation et mise en production de systèmes IA.

BLOC COMPÉTENCES PAGE 1

- LLM Inference & GPU : PyTorch, CUDA, quantization AWQ/GPTQ/GGUF, llama.cpp, vLLM.
- GenAI : RAG, LoRA/SFT, Hugging Face, orchestration multi-agent.
- Speech AI : Coqui/STT, Whisper, VAD, OpenVoice, TFLite.
- Engineering : Python, Linux, Docker, Git/CI/CD, FastAPI.

EXPÉRIENCE RÉCENTE - VERSION PLUS CIBLÉE

- Développement de pipelines RAG et fine-tuning de LLM pour la compréhension et la synthèse de documents spécialisés.
- Développement de pipelines de données et de modèles prédictifs pour l'analyse de workflows de devis et facturation.
- Développement d'une infrastructure de backtest et de stratégies quantitatives basées sur l'extraction de signaux ML sur données de marché.

La puce blockchain peut être déplacée en page 2 ou supprimée pour une candidature LLM/GPU, sauf si elle correspond à l'offre.

13. ANOMALIES, RISQUES ET POINTS DE REJET

- Incohérence de preuve : le pitch revendique des kernels CUDA/Triton sur-mesure, mais la preuve AutoAWQ visible décrit surtout le build process et la compatibilité Torch.

- Ambiguïté de statut : « Mozilla & Coqui-AI » peut être interprété comme un emploi. Clarifier s'il s'agit de contribution open source, mandat ou emploi.
- Ambiguïté de positionnement : titre GPU/inference vs expérience récente Data Scientist multi-domaines.
- Dates hétérogènes FR/EN et formats mixtes.
- Page 1 sans bloc de compétences clés.
- Pitch trop long pour la présélection.

Risque de rejet RH : moyen sur les postes qui exigent un diplôme universitaire/HES/EPFL/ETH ou un nombre d'années formelles dans un rôle précis. Le CV compense partiellement par les contributions techniques.

Risque de rejet manager : surtout si les affirmations CUDA / distributed inference ne résistent pas à une vérification technique détaillée.

Risque de rejet ATS : faible à modéré ; la structure est bonne, mais la cible doit être plus cohérente et les intitulés/dates plus homogènes.

14. EXEMPLES AVANT / APRÈS

Avant : Ingénieur autodidacte avec des PR mergées dans les kernels de quantification CUDA...

Après : AI Systems Engineer spécialisé en inférence LLM, speech AI et déploiement GPU, avec des contributions mergées dans AutoAWQ, Hugging Face Transformers et Coqui-STT.

Avant : Optimisation de kernels CUDA : PR mergées dans AutoAWQ... mise à jour du build process...

Après : Contributions AutoAWQ / AutoAWQ_kernels : amélioration du build et de la compatibilité PyTorch pour la compilation de kernels de quantification CUDA.

Avant : Pipeline de transcription vocale temps réel ... avec latence minimale

Après : Pipeline de transcription vocale temps réel : architecture client-serveur combinant Faster-Whisper et VAD, avec synthèse vocale via OpenVoice v2.

Avant : Couvrir toute la stack ... aussi à l'aise pour optimiser un kernel CUDA que pour concevoir un serveur d'inférence distribué.

Après : Combine une compréhension low-level GPU avec la conception de systèmes d'inférence et de pipelines IA de bout en bout.

15. CHECK-LIST FINALE AVANT ENVOI

- Choisir un seul titre cible par candidature.
- Raccourcir le pitch à 3 ou 4 lignes.
- Faire remonter 4 blocs de compétences clés en page 1.
- Sélectionner 3 preuves fortes et les placer avant les détails secondaires.
- Clarifier le statut de Mozilla / Coqui-AI et de Waser Technologies.
- Vérifier chaque affirmation forte : CUDA/Triton, PyTorch internals, inference distribuée.
- Harmoniser toutes les dates au format mm.yyyy.
- Uniformiser le français des intitulés de sections.
- Remplacer +41 (0) par +41 pour le numéro suisse.
- Ajouter disponibilité / préavis / permis uniquement si pertinent.
- Adapter les mots-clés et l'ordre des réalisations à l'offre ciblée sans keyword stuffing.
- Tester le PDF par copier-coller texte et vérifier les liens.
- Nommer le fichier Danny_Waser_CV_<PosteCible>.pdf.
- Relire la cohérence entre titre, pitch, compétences et preuves.

- Préparer les réponses d'entretien sur les PR, le rôle exact dans les projets, les gains de performance et l'architecture des systèmes.

CONCLUSION

Verdict : passe avec réserves. Le CV possède un vrai potentiel de différenciation grâce aux contributions open source, au speech AI et aux systèmes LLM/GPU. La priorité n'est pas d'ajouter davantage de technologies : elle est de rendre la cible plus nette, de faire remonter les preuves fortes en page 1 et d'aligner exactement chaque revendication technique avec une preuve vérifiable.

La meilleure candidature n'est pas celle qui paraît parfaite : c'est celle qui paraît vraie, ciblée, vérifiable et défendable en entretien.