

Danny Waser

AI Systems Engineer - LLM Inference & GPU

danny@wasertech.ch | +41 79 000 00 00 | Lausanne, Suisse
github.com/wasertech | huggingface.co/wasertech | wasertech.github.io

PROFIL

57 PRs mergées dans 12+ dépôts externes: huggingface/transformers (164k stars), django-cms (10.6k stars), coqui-ai/STT (2.6k stars), AutoAWQ (2.3k stars), EsupPortail (gouvernement), ixray (moteur de jeu). Conception et exploitation d'un serveur d'inférence local de production (96GB RAM, dual RTX Titan 24GB) servant plusieurs presets LLM (7B-70B) avec décodage spéculatif et routage de modèles. Construction d'un assistant multi-agent de production (Hermes Agent) orchestrant des agents spécialisés pour les opérations système, la recherche web, l'édition de fichiers et la génération de code via langage naturel - sur hardware local avec inférence sur site.

COMPÉTENCES MÉTIER

- Local LLM Inference Stack (96GB RAM · 2× RTX Titan 24GB)
- Multi-Agent LLM Orchestration (multi-agent · local inference)
- SFT Dataset Curation & Fine-tuning (50k+ examples · multi-source)
- Speech Recognition (ASR) (12+ PRs merged · coqui-ai/STT 2.6k stars)
- French STT Model Training & Publication (WER -10% · 2× data quality)

COMPÉTENCES MÉTHODOLOGIQUES

- Open Source Contributions (57 PRs · 12+ repos)

CERTIFICATIONS

- Certificat Professionnel Google Advanced Data Analytics** | Google @ Coursera (10.2023 - 11.2023)

LANGUES

Français (C2) · Anglais (C1) · Espagnol (C1) · Allemand (B1)

Références sur demande

EXPÉRIENCE PROFESSIONNELLE

Waser Technologies

01.2020 - 07.2023

Développeur IA & Fondateur (Activité Entrepreneuriale)

- Optimisation de kernels CUDA : PR mergées dans [AutoAWQ #573](#) et [AutoAWQ_kernels #29](#) - mise à jour du build process pour compatibilité Torch et compilation flexible de kernels de quantification.
- Traducteur multi-modal (github.com/wasertech/Translator) : CLI de traduction par lots avec support PO, détection multi-langue et intégration NLLB-200. 4 PR mergées (locale, type safety, workflow PO).
- Pipeline de transcription vocale temps réel (gitlab.com/waser-technologies/technologies/listen) : Architecture client-serveur de bout en bout combinant Faster-Whisper et VAD pour la transcription en direct avec latence minimale ; associé à OpenVoice v2 pour le clonage vocal few-shot et la TTS.
- Orchestrateur LLM multi-agent (gitlab.com/waser-technologies/technologies/assistant) : Assistant de production sur hardware local (96GB RAM, dual RTX Titan) - orchestre des agents spécialisés pour les opérations système, la recherche web et l'édition de fichiers via langage naturel, avec inference sur site.
- HuggingFace transformers ([PR #42864](#)) : Correction mergée pour l'initialisation de l'activation xielu d'ApertusMLP utilisant torch_dtype.

Mozilla & Coqui-AI

11.2021 - 12.2022

Développeur en reconnaissance vocale

- 12 PR mergées dans coqui-ai/STT sur 1.5 ans : Corrections de gestion mémoire pendant l'entraînement batch [#2205](#), optimisation d'export de graphe TF [#2222](#) - suppression du format memmapped, pipeline d'export TFLite [#2221](#), refactoring du module d'optimisation LM [#2116](#), [#2203](#), corrections d'importers [#2148](#), [#2111](#) et améliorations CI [#2285](#).
- Maintenance CommonVoice FR (github.com/common-voice/commonvoice-fr) : Réimplémentation de l'image d'entraînement DeepSpeech avec le framework STT pour continuer la transcription française après la dépréciation de DeepSpeech.
- Modèles français publiés (github.com/wasertech/commonvoice-fr/releases) : Entraînement de nouveaux modèles français avec 2x plus de données augmentées de meilleure qualité, réduisant le taux d'erreur de mot moyen de 10%.
- Migration DeepSpeech → STT : Pilotage de la migration du pipeline d'entraînement francophone de DeepSpeech (déprécié) vers la codebase STT.

Synthflow AI

01.2024 - 03.2024

Ingénieur en Intelligence Artificielle (IA)

- Systèmes conversationnels multi-agents : Conception et prototypage de systèmes d'appels vocaux de production déployant plusieurs agents LLM spécialisés en tandem pour la téléphonie.
- Gestion de dialogue temps réel : Implémentation itérative de gestionnaires de dialogue basés sur LLM avec ingénierie de prompt dynamique pour des temps de réponse inférieurs à la seconde en appel en direct.
- Cycle R&D rapide : Du concept au prototype fonctionnel en moins de 2 semaines par fonctionnalité, en travaillant directement avec la direction sur les exigences produit.

Idéal Isolation Sàrl & DF Innovation Sàrl

09.2024 - 03.2026

Data Scientist

- Idéal Isolation - Analyse Opérationnelle : Analyse stratégique des goulets d'étranglement dans les workflows de devis et facturation ; développement de pipelines de données et modèles prédictifs pour optimiser l'allocation des ressources et réduire les délais de traitement.
- DF Innovation - R&D en IA Générative : Construction de pipelines RAG sur mesure et fine-tuning de LLMs pour la compréhension et la synthèse de documents spécialisés.
- DF Innovation - Trading Algorithmique : Développement de stratégies de trading quantitatives utilisant l'extraction de signaux par ML sur des données de marché, avec infrastructure de backtest et analyse de performance.
- DF Innovation - Blockchain : Prototypage de smart-contracts Solana pour des opérations de marché automatisées.

FORMATION

- **Diplôme Commercial (CFC + MPC)** | École de Culture Générale et de Commerce, Gymnase de Beaulieu, Lausanne (08.2014 - 07.2017)

CONTRIBUTIONS OPEN SOURCE

- Open Source Contributions | 57 PRs mergées dans 12+ dépôts externes: huggingface/transformers (164k stars), django-cms (10.6k stars), coqui-ai/STT (2.6k stars), AutoAWQ (2.3k stars), EsupPortail (gouvernement), ixray (moteur de jeu). 8 modèles + 6 datasets publiés sur HuggingFace. (57 PRs · 12+ repos · 164k stars max · 8 models)