

DANNY WASER

INGÉNIEUR AI/ML | SYSTÈMES AI, LLM & AUTOMATISATION

+41 (0) 78 911 98 34 | danny@waser.tech | Lausanne, CH

Disponibilité : immédiate

GitHub | LinkedIn | HF | waser.tech



PROFIL

Ingénieur AI/ML qui conçoit des systèmes AI de bout en bout : du problème complexe à la production, couvrant pipelines de données, inférence et fine-tuning de LLMs, RAG, orchestration multi-agents, parole et automatisation intelligente. 57 PRs mergées dans 12+ dépôts open source (Coqui-STT, AutoAWQ, HuggingFace) ; réduction de 10% du taux d'erreur de parole sur les modèles français ; inférence locale de modèles 70B+ sur station dual-GPU. Collaboration directe avec la direction : prototype fonctionnel en moins de 2 semaines par fonctionnalité. Le fil rouge de mon travail : l'interface entre une information à volume élevé et les personnes qui agissent dessus.

COMPÉTENCES PROFESSIONNELLES

DATA SCIENCE & ANALYSE:

- Analyses prescriptives et prédictives : apprentissage automatique, modèles prédictifs, algorithmes, aide à la décision
- Exploration et préparation des données : recueil multi-sources, préparation, vérification de la véracité, visualisation
- Cycle de vie des données : outils d'analyse, interprétation des résultats, nouvelles sources de données

DÉVELOPPEMENT & ARCHITECTURE:

- Conception et développement d'applications : développement, débogage, documentation, intégration, mise en service
- Conception de l'architecture : interopérabilité, évolutivité, sécurité, gestion de la vulnérabilité
- Conception des applications : structures de données, langages de modélisation, approche itérative

GESTION & INNOVATION:

- Gestion des projets et du portefeuille de projets : planification, ressources et budget, optimisation coûts-délais, livraison
- Alignement stratégique métier : besoins métier, architecture d'entreprise, efficacité des processus, décisions stratégiques
- Innovation : solutions créatives, nouveaux concepts, mode de pensée innovant

COMPÉTENCES TECHNIQUES

Administration systèmes:

Centre de calcul, Headscale

Base de données:

ETL, MariaDB, MongoDB, MySQL, PostgreSQL, SQL Server, SQLite, FTS5

Bureautique / Gestion:

MS Office, Microsoft 365, LibreOffice

CMS:

Wordpress, Django CMS

Design Patterns:

MVC, MVVM

DevOps:

Ansible, CD, CI, Docker, GitHub Actions, GitLab, Grafana, Kubernetes, Prometheus, YAML, GNU, Arch Linux, Manjaro, Serveur GPU NVIDIA, CUDA Toolkit, Git & CI

Interface de programmation (API):

DirectX, DOM, Vulkan, MCP, A2A

ITSM & Services:

JIRA

Langages informatiques:

Bash, C++, CSS, HTML, Javascript, JSON, PHP, Python, SH, Shell, SQL, TypeScript, XML, CUDA C++, Kernels Triton, xonsh

Matériel & Equipement:

Desktop, Laptop, Imprimante, Périphériques, Routeurs, Smartphone, tablette, Switch

Réseaux, protocoles & Télécommunications:

3G, 4G, 5G, DHCP, Ethernet, HTTP, Internet, IP, LAN, WAN, POP3, SMTP, TCP, VoIP, Wifi, WebSocket

Virtualisation:

HyperV, VirtualBox, VMWare, VMWare Workstation

Web Service:

REST

3D & Game Development:

Godot, Ursina

Processus:

BPM

Test:

BDD, TDD

Applications serveur:

Apache Tomcat, Apache HTTP Server, SearXNG, Freqtrade

BI & Data science:

Tableau

Blockchain:

Ethereum, Solana

Cloud:

AWS, Azure, Firebase, Google Cloud Platform

Data Science:

Jupyter, Pandas, NumPy, Pipelines de données, Curatation de datasets SFT

Framework:

Angular, Bootstrap, Django, jQuery, Node, PyTorch, React, Vue, TensorFlow, FastAPI, Hermes Agent

Machine Learning:

Deep learning, Machine learning, NLP, MLOps, Quantification AWQ, Quantification GPTQ, Quantification GGUF, PyTorch Internals, llama.cpp, vLLM, Orchestration multi-agent, Pipelines RAG, Fine-tuning LoRA, Fine-tuning SFT, Écosystème Hugging Face, Ingénierie de prompt, DeepSpeech, Coqui STT, Whisper, OpenVoice, Détection d'activité vocale, FFmpeg, OmniRoute Gateway, crawl4ai, Docling, Docling Serve, OpenCV, Pillow, pi, oh-my-pi, opencode, GitHub Copilot

OS:

Android, iOS, Linux, OSX, Unix, Windows, Windows serveur, systemd

Sécurité:

Antivirus, Firewall, GPO, Spyware, SSL, VPN

Test & Qualité:

Selenium, Playwright

Visioconférence:

Teams, Zoom, kMeet

Web Scraping & Automatisation:

BeautifulSoup4, Scrapy

Gouvernance:

Lean, RGPD

Projet:

Agile, DevOps, Kanban, Scrum

CERTIFICATIONS

Certificat Professionnel Google Advanced Data Analytics (Google @ Coursera | 10.2023 à 11.2023)

LANGUES

Français (C2) | Anglais (C1) | Espagnol (C1) | Allemand (B1)

EXPÉRIENCE PROFESSIONNELLE

Idéal Isolation Sàrl & DF Innovation Sàrl

09.2024 à 03.2026

Data Scientist

- Analyse opérationnelle : goulets d'étranglement des workflows devis/facturation ; pipelines de données + modèles prédictifs pour l'allocation des ressources.
- R&D en ML génératif : pipelines RAG sur mesure, fine-tuning de LLMs pour la compréhension et la synthèse de documents.
- Trading algorithmique : extraction de signaux ML sur données de marché, infrastructure de backtest, analyse de performance, bot de production (live + dry-run).
- Blockchain : prototypes de smart-contracts Solana pour des opérations de marché automatisées.

Synthflow AI

01.2024 à 03.2024

Ingénieur en Machine Learning

- Systèmes conversationnels multi-agents : systèmes d'appels vocaux de production avec plusieurs agents LLM spécialisés en tandem pour la téléphonie.
- Gestion de dialogue temps réel : gestionnaires de dialogue basés LLM, ingénierie de prompt dynamique, temps de réponse < 1 s en appel live.
- Cycle R&D rapide : du concept au prototype fonctionnel en < 2 semaines par fonctionnalité ; collaboration directe avec la direction.

Mozilla & Coqui-AI

11.2021 à 12.2022

Développeur reconnaissance vocale

- 12 PR mergées dans coqui-ai/STT : gestion mémoire en entraînement batch [#2205](#), export de graphe TF [#2222](#), export TFLite [#2221](#), optimisation LM [#2116](#).
- Maintenance CommonVoice FR ([PR #168](#)) : image d'entraînement DeepSpeech sur le framework STT.
- Modèles français publiés : 2x plus de données augmentées de meilleure qualité, -10% de taux d'erreur de mot moyen.
- Migration DeepSpeech → STT : pilotage de la migration du pipeline francophone.

Waser Technologies

01.2020 à 07.2023

Développeur ML & Fondateur (Activité Entrepreneuriale)

- Optimisation de kernels CUDA : 2 PR mergées dans [AutoAWQ #573](#) & [AutoAWQ_kernels #29](#) ; pipeline de quantification.
- Traducteur multi-modal ([wasertech/Translator](#)) : CLI par lots, NLLB-200, 4 PR mergées.
- Pipeline vocal temps réel ([waser-technologies/listen](#)) : Faster-Whisper + VAD, transcription faible latence, OpenVoice v2.
- Orchestrateur LLM multi-agents ([waser-technologies/assistant](#)) : assistant de production sur hardware local (96GB RAM, 2xRTX Titan) ; ops en langage naturel, inférence sur site.
- MLOps de production : déploiements conteneurisés avec passthrough GPU (Docker Compose), supervision de services (systemd, s6-overlay), cycle de vie des modèles et monitoring de performance sur la stack d'inférence locale.
- HuggingFace transformers ([PR #42864](#)) : correction mergée d'initialisation.

FORMATION

• Diplôme Commercial (CFC + MPC)

École de Culture Générale et de Commerce | 08.2014 à 07.2017

PORTFOLIO

Hugging Face Profile | Profil Hugging Face officiel hébergeant des LLM open-source, des modèles de parole et des ensembles de données ML spécialisés.

Assistant | Shell LLM multi-agent orchestrant des agents spécialisés pour les opérations système, la recherche web et l'édition de fichiers via prompt naturel.

Listen | Système de reconnaissance vocale en temps réel avec architecture serveur-client utilisant Faster-Whisper et VAD pour une transcription efficace.

Say | Outil de synthèse vocale générant des voix personnalisables de haute qualité à partir d'échantillons de 10 secondes via OpenVoice v2.

Translator | CLI de traduction par lots exploitant les pipelines de traduction Hugging Face (NLLB-200 et modèles compatibles) avec support complet des fichiers PO préservant les métadonnées.

CONTRIBUTIONS OPEN SOURCE

- **Mozilla Common Voice**
Pipeline d'entraînement de modèles STT français
- **huggingface/transformers** | 1 PR (164,514 stars)
fix: Initialize ApertusMLP's xielu activation using `torch\_dtype` (+7/-2)
- **django-cms/django-cms** | 1 PR (10,665 stars)
fix: typos in French translations (+1/-1)
- **coqui-ai/STT** | 12 PRs (2,606 stars)
Bring back importer for TrainingSpeech (+293/-0)
Add excluded sentences to LM (+119/-17)
Fix CCPMF importer (+97/-31)
Make lm_optimizer.py as python module (+71/-47)
Workaround batch size memory test (+61/-7)
export to tflite using python37 venv (+32/-13)
Fix LM optimization script importing non existing function and add CI (+37/-1)
Fix importers save_excluded_max_sec_to_disk flag (+31/-4)
Update BUILDING.rst (+8/-8)
Updated missing checkpoint path error message (+11/-1)
Remove `convert\_graphdef\_memmapped\_format` (+0/-4)
[FIX]: lm_optimize module import from training utils (+1/-1)
- **casper-hansen/AutoAWQ** | 1 PR (2,349 stars)
Let installed PyTorch decide required version number (+2/-1)
- **ixray-team/ixray-1.6-stcop** | 3 PRs (442 stars)
Support common cross-platform rendering pipeline thru Vulkan (+3186/-42)
Fix language reload and translate inventory items when switching langu (+173/-12)
Add support for preferred fallback language (+90/-4)
- **coqui-ai/STT-models** | 6 PRs (153 stars)
Update cv-fr v0.8 and add v0.9 (+620/-4)
New release 0.8.3 for French STT (+600/-0)
Fix broken link for chatio (+1/-1)
Update MODEL_CARD.md (+1/-1)
Update MODEL_CARD.md (+1/-1)
Update MODEL_CARD.md (+1/-1)
- **coqui-ai/STT-examples** | 3 PRs (132 stars)
Add Django streaming example (+1492/-0)
Update README.md (+3/-3)
Update README.rst (+1/-0)
- **casper-hansen/AutoAWQ_kernels** | 1 PR (80 stars)
Update build process for flexibility and torch version compatibility (+26/-9)
- **EsupPortal/Esup-Pod** | 1 PR (48 stars)
Use -STT (+21/-21)
- **coqui-ai/stt-model-manager** | 4 PRs (26 stars)
Fix security vulnerabilities (+3898/-2587)
Version 0.0.21-GM (+88/-26)
Loosen STT version requirement (+4/-4)
Loosen `coqpit` (+1/-1)
- **dperelman/gamepad-util** | 1 PR (15 stars)
Update identify_evdev.py (+1/-1)
- **ixray-community/ixray-unofficial-patch** | 1 PR (2 stars)
Update README with mod loading instructions (+3/-0)

INTÉRÊTS PERSONNELS

Fan d'astronomie, de space opera, de sentiers de montagne, de slam conscient, d'aventures épiques